Redes Neuronales y Aprendizaje Profundo

Curso de Deep Learning

Universidad EAFIT

Laboratorio # 3 – Núcleo IV (Valor: 10%)

De modelo de lenguaje a asistente de IA - Ajuste supervisado con LoRA

En este laboratorio se ajusta el modelo Qwen2.5-0.5B con ejemplos de Dolly en español. Se desarrollan siete actividades de código y se compara el desempeño del modelo antes y después del ajuste. Se recomienda utilizar una GPU T4 en Kaggle o Colab.

Notebook: Taller_SFT_LoRA_pregrado.ipynb

1. Objetivos

Ajustar el modelo de lenguaje base Qwen2.5-0.5B con ejemplos de instrucción en español, usando LoRA, observar cuantitativamente (pérdida NLL) y cualitativamente (comparación de respuestas) el efecto del ajuste.

- Comprender la diferencia entre preentrenamiento y ajuste fino supervisado.
- Preparar datos en el formato prompt/completion requerido por SFT.
- Configurar y aplicar un adaptador LoRA mediante la biblioteca PEFT.
- Interpretar la curva de pérdida de entrenamiento y validación.
- Analizar críticamente las limitaciones del ajuste con datos reducido.

2. Contexto: de predecir texto a conversar

2.1 El nacimiento de los modelos de lenguaje: Los modelos de lenguaje existen desde la década de 1950, cuando Claude Shannon aplicó la teoría de la información a secuencias de texto. Durante décadas los modelos fueron estadísticos (n-gramas): estimaban la probabilidad del siguiente token mirando los n anteriores. Su capacidad era limitada y olvidaban el contexto rápidamente. En 2017 el paper «Attention is All You Need» (Vaswani et al.) cambió todo al introducir la arquitectura Transformer. Este mecanismo de atención permite al modelo relacionar cualquier par de tokens en la secuencia, sin importar la distancia, dándole una memoria de largo alcance que los modelos anteriores no tenían.

2.2 El problema del modelo base: Entrenar un Transformer grande sobre enormes corpus de texto produce un modelo base (también llamado foundation model o pretrained model). Este modelo aprende una representación rica del lenguaje: gramática, hechos del mundo, capacidad de razonamiento. Pero tiene un problema fundamental: Ante una pregunta como «¿Qué es un átomo?», el modelo base puede continuar el texto con otra pregunta, una definición incompleta o una secuencia incoherente. El preentrenamiento optimiza la predicción del siguiente token.

Esto se debe a que el preentrenamiento optimiza una sola cosa: predecir el siguiente token del corpus. Internet —la fuente de esos datos— está lleno de texto continuo (artículos, libros, foros), no de pares pregunta-respuesta bien formados. El modelo aprende el idioma del humano, pero no aprende a ayudar al humano.

2.3 La solución - Supervised Fine-Tuning (SFT): En 2022, el paper «Training Language Models to Follow Instructions» (Ouyang et al., OpenAI) —el artículo que introdujo InstructGPT, predecesor de ChatGPT— demostró que con un número sorprendentemente pequeño de ejemplos de instrucción + respuesta se puede alinear el comportamiento del modelo. La idea del SFT es simple: se toman pares (instrucción, respuesta correcta) curados por humanos, y se sigue entrenando el modelo sobre ellos. La función de pérdida es la misma (cross-entropy sobre tokens), pero ahora solo se mide sobre los tokens de la respuesta, no sobre la instrucción. Así el modelo aprende a completar respuestas útiles dado un prompt de instrucción.

3. ¿Por qué LoRA? El problema del ajuste fino clásico

3.1 El costo del ajuste fino completo: Ajustar un modelo significa actualizar sus pesos mediante gradiente. Para un modelo de 500 M de parámetros como Qwen2.5-0.5B, eso implica almacenar en GPU no solo los parámetros (fp32: ~2 GB) sino también los gradientes y los estados del optimizador (Adam necesita 2 tensores extra por parámetro): fácilmente 8-12 GB solo para el ajuste. Para modelos de 7B, 13B o 70B, el costo se vuelve inaccesible sin infraestructura especializada.

3.2 La intuición de LoRA: El paper «LoRA: Low-Rank Adaptation of Large Language Models» (Hu et al., 2021) observó un hecho empírico: cuando se ajusta un modelo, la matriz de cambio de pesos ΔW tiene un rango intrínseco muy bajo. Es decir, el ajuste no explora todo el espacio de parámetros: se mueve en un subespacio de dimensión mucho menor. LoRA aprovecha esto: en lugar de modificar directamente W, agrega dos matrices pequeñas A y B tales que $\Delta W = B \cdot A$, donde el rango r es mucho menor que las dimensiones originales. Solo A y B se entrenan; W permanece congelado.

3.3 Ventajas concretas en este taller

- Solo se entrena ~1 % de los parámetros totales del modelo.
- El modelo original no se modifica: se puede desactivar LoRA y recuperar el base.
- Cabe en una GPU T4 de 16 GB, disponible gratis en Kaggle y Colab.
- El entrenamiento de 2 000 ejemplos tarda ~15-25 minutos en T4.

En este laboratorio se aplica LoRA a las proyecciones de atención q_proj, k_proj, v_proj y o_proj, con rango r = 16 y factor de escala alfa = 32. El ajuste actualiza una fracción de los parámetros y conserva congelados los pesos originales.

3.3 ¿Por qué esto es relevante hoy?: ChatGPT, Claude, Gemini y la mayoría de asistentes modernos no son simplemente modelos base. Todos pasaron por una fase de SFT (y usualmente RLHF o DPO adicional) para aprender a seguir instrucciones. Entender este proceso es entender cómo se construyen los sistemas de IA más usados en el mundo. Además, el ajuste fino eficiente con LoRA es hoy la técnica estándar en la industria para personalizar modelos grandes a dominios específicos (medicina, derecho, soporte técnico, idiomas minoritarios) sin el costo de reentrenar desde cero.

4. Procedimiento experimental

El notebook se organiza en diez pasos e incluye siete actividades de implementación (TODOs).

- **Paso 0 · Instalar dependencias:** Se instalan las versiones trl==1.16.0 y peft==0.21.2. Si se modifican las dependencias, se reinicia la sesión antes de continuar con el paso 1.
- **Paso 1 · Preparar el entorno:** Se importan las bibliotecas, se fijan las semillas y se verifica la disponibilidad de GPU. La salida 'cuda' indica que la GPU está habilitada. En Kaggle se activa en Settings > Accelerator > GPU T4.
- **Paso 2 · Cargar el modelo base:** Se descarga Qwen2.5-0.5B desde Hugging Face (~1 GB). Se inspecciona su arquitectura: 500 M de parámetros, 24 bloques Transformer, dimensión oculta d = 896 y un vocabulario de ~151 000 tokens.
- **Paso 3 · Formato de entrenamiento:** Se define la función prompt(), que construye la cadena 'Usuario: \nAsistente:'. Este formato se utiliza durante el ajuste y la generación.
- **Paso 4 · Observar el modelo base:** Se generan respuestas con el modelo base y se examinan su coherencia y la emisión del token de fin.
- **Paso 5 · Cargar y dividir datos:** Se descarga Dolly 15k en español (argilla/databricks-dolly-15k-curated-multilingual). Se filtran los ejemplos sin contexto adicional y de longitud moderada. Se obtienen aproximadamente 6 000 ejemplos.
- **Paso 6 · Configurar LoRA y el entrenador:** Se configura LoRA (r = 16, alfa = 32) en las cuatro proyecciones de atención y se inicializa SFTTrainer. Con completion_only_loss=True, la pérdida se calcula sobre los tokens de la respuesta.
- **Paso 7 · Máscara de pérdida:** Se identifican los tokens que contribuyen a la pérdida. Las posiciones con etiqueta -100 se excluyen del cálculo.
- **Paso 8 · Evaluar y entrenar:** Se mide la pérdida de validación antes y después de una época de ajuste (~250 pasos con GPU) y se grafica la evolución de la pérdida.

Paso 9 · Comparar respuestas: Se generan respuestas con el modelo ajustado usando las mismas entradas del paso 4 y se realiza una comparación cualitativa.

5. Criterios de evaluación

La evaluación se centra en la comprensión del procedimiento, la implementación y la interpretación de resultados. La calidad de las respuestas generadas se considera en el análisis cualitativo.

Criterio	Descripción	Ponderación
TODOs de código	Siete actividades de código completadas correctamente.	50 %
Respuestas conceptuales	Siete respuestas claras y pertinentes.	35 %
Preguntas de cierre	Tres respuestas al final del notebook.	15 %

6. Entrega

El notebook del laboratorio debe enviarse al correo electrónico del docente con el asunto Lab#3-Grupo-#, reemplazando el último símbolo # por el número del grupo. La entrega debe realizarse a más tardar el viernes 6 de noviembre a las 11:59 a.m.